T.C.

Atatürk Üniversitesi

Mühendislik Fakültesi

Bilgisayar Mühendisliği Bölümü

YAPAY ZEKAYA GİRİŞ DERSİ DÖNEM PROJESİ

ÖĞRENCİNİN

Adı-Soyadı : Helin BORA
Numarası : 220707056
Proje Konusu : Cilt Hastalıklarının Tespitinde Derin Öğrenme Modellerinin Karşılaştırılması

ARALIK 2025

ERZURUM

1. AMAÇ VE PROBLEM TANIMI

Cilt hastalıkları, görsel olarak ayırt edilmesi zor olabilen ve doğru teşhis edilmediğinde sağlık açısından ciddi sonuçlara yol açabilen hastalıklardır. Günümüzde dermatolojik tanılar çoğunlukla uzman görüşüne dayalı olarak yapılmakta olup, bu süreç zaman alıcı olabilmekte ve öznel değerlendirmeler içerebilmektedir. Bu durum, otomatik ve destekleyici sistemlere olan ihtiyacı artırmaktadır.

Bu raporda, cilt hastalıklarının görüntüler üzerinden otomatik olarak sınıflandırılması problemi ele alınmıştır. Projenin temel amacı, derin öğrenme tabanlı yöntemler kullanarak farklı cilt hastalıklarının sınıflandırılabilirliğini incelemek ve farklı model yaklaşımlarının performanslarını karşılaştırmaktır. Bu kapsamda, bir adet özel olarak tasarlanmış evrişimsel sinir ağı modeli (MyCNN) ile birlikte çeşitli önceden eğitilmiş derin öğrenme modelleri kullanılmıştır.

Çalışma, tamamen uygulama odaklı bir ders projesi olarak tasarlanmıştır. Teorik detaylardan ziyade, veri setinin hazırlanması, modellerin eğitilmesi, test edilmesi ve elde edilen sonuçların karşılaştırılması süreçlerine odaklanılmıştır. Elde edilen sonuçlar, kullanılan modellerin sınıflandırma başarıları açısından değerlendirilmiş ve hangi yaklaşımın daha etkili olduğu analiz edilmiştir.

Bu raporun amacı, derin öğrenme yöntemlerinin cilt hastalıklarının sınıflandırılmasındaki başarımını uygulamalı olarak ortaya koymak ve elde edilen sonuçları açık ve anlaşılır bir biçimde sunmaktır.

2. KULLANILAN VERİ SETİ

Bu çalışmada, cilt hastalıklarının görüntüler üzerinden sınıflandırılmasına yönelik bir veri seti kullanılmıştır. Veri seti, beş farklı cilt hastalığına ait görüntülerden oluşmakta olup, her sınıf ayrı bir klasör altında düzenlenmiştir. Bu klasör yapısı, derin öğrenme modellerinin etiket bilgilerini otomatik olarak öğrenmesine imkân tanımaktadır.

Çalışmada kullanılan sınıflar aşağıda listelenmiştir:

- Nail Psoriasis
- SJS-TEN
- Vitiligo
- Acne
- Hyperpigmentation

Veri setinde yer alan görüntüler RGB formatındadır ve farklı çözünürlüklerde bulunmaktadır. Görüntüler doğrudan modele verilmeden önce ön işleme aşamasından geçirilmiş ve tüm modeller için ortak bir giriş boyutu kullanılmıştır.

Veri seti, model performansının sağlıklı bir şekilde değerlendirilebilmesi amacıyla üç alt kümeye ayrılmıştır. Bu kapsamda görüntülerin %80'i eğitim, %10'u doğrulama ve %10'u test verisi olarak kullanılmıştır. Eğitim verileri modelin öğrenme sürecinde kullanılırken, doğrulama verileri model performansının izlenmesi ve en iyi model ağırlıklarının seçilmesi amacıyla değerlendirilmiştir. Test verileri ise eğitim sürecine dâhil edilmemiş ve nihai performans ölçümü için kullanılmıştır.

Derin öğrenme modellerinin sabit giriş boyutu gereksinimi nedeniyle tüm görüntüler 224×224 piksel boyutuna yeniden ölçeklendirilmiştir. Ayrıca, görüntülerin piksel değerleri normalize edilerek öğrenme sürecinin daha kararlı hale gelmesi sağlanmıştır. Eğitim aşamasında, modelin genelleme yeteneğini artırmak amacıyla veri artırma tekniklerinden yararlanılmıştır. Bu teknikler yalnızca eğitim verileri üzerinde uygulanmış, doğrulama ve test verileri bu işlemlerin dışında tutulmuştur.

Bu veri seti yapısı ve uygulanan ön işleme adımları, cilt hastalıklarının çok sınıflı görüntü sınıflandırma problemi için uygun bir temel sunmaktadır.

3. YÖNTEM VE UYGULAMA AKIŞI

Bu bölümde, çalışmada kullanılan yöntemler ve uygulama süreci ayrıntılı olarak açıklanmaktadır. Çalışmanın genel amacı, cilt hastalıklarına ait görüntülerin derin öğrenme tabanlı modeller kullanılarak sınıflandırılmasıdır. Bu kapsamda veri setinin hazırlanmasından model eğitimine ve performans değerlendirmesine kadar olan tüm adımlar sistematik bir şekilde gerçekleştirilmiştir.

3.1. Genel Uygulama Akışı

Çalışmada izlenen genel yöntem aşağıdaki temel aşamalardan oluşmaktadır:

1. Veri setinin hazırlanması ve ön işleme adımları
2. Eğitim, doğrulama ve test kümelerinin oluşturulması
3. Derin öğrenme modellerinin tanımlanması
4. Modellerin eğitilmesi
5. Test verisi üzerinde performans değerlendirmesi
6. Modellerin karşılaştırılması

Bu adımlar, uygulama sürecinin düzenli ve tekrar edilebilir olmasını sağlamak amacıyla bir akış diyagramı ile gösterilmiştir. Akış diyagramı, veri girişinden sonuçların elde edilmesine kadar olan süreci görsel olarak özetlemektedir.

Şekil 3.1. Çalışmada izlenen genel uygulama akış diyagramı

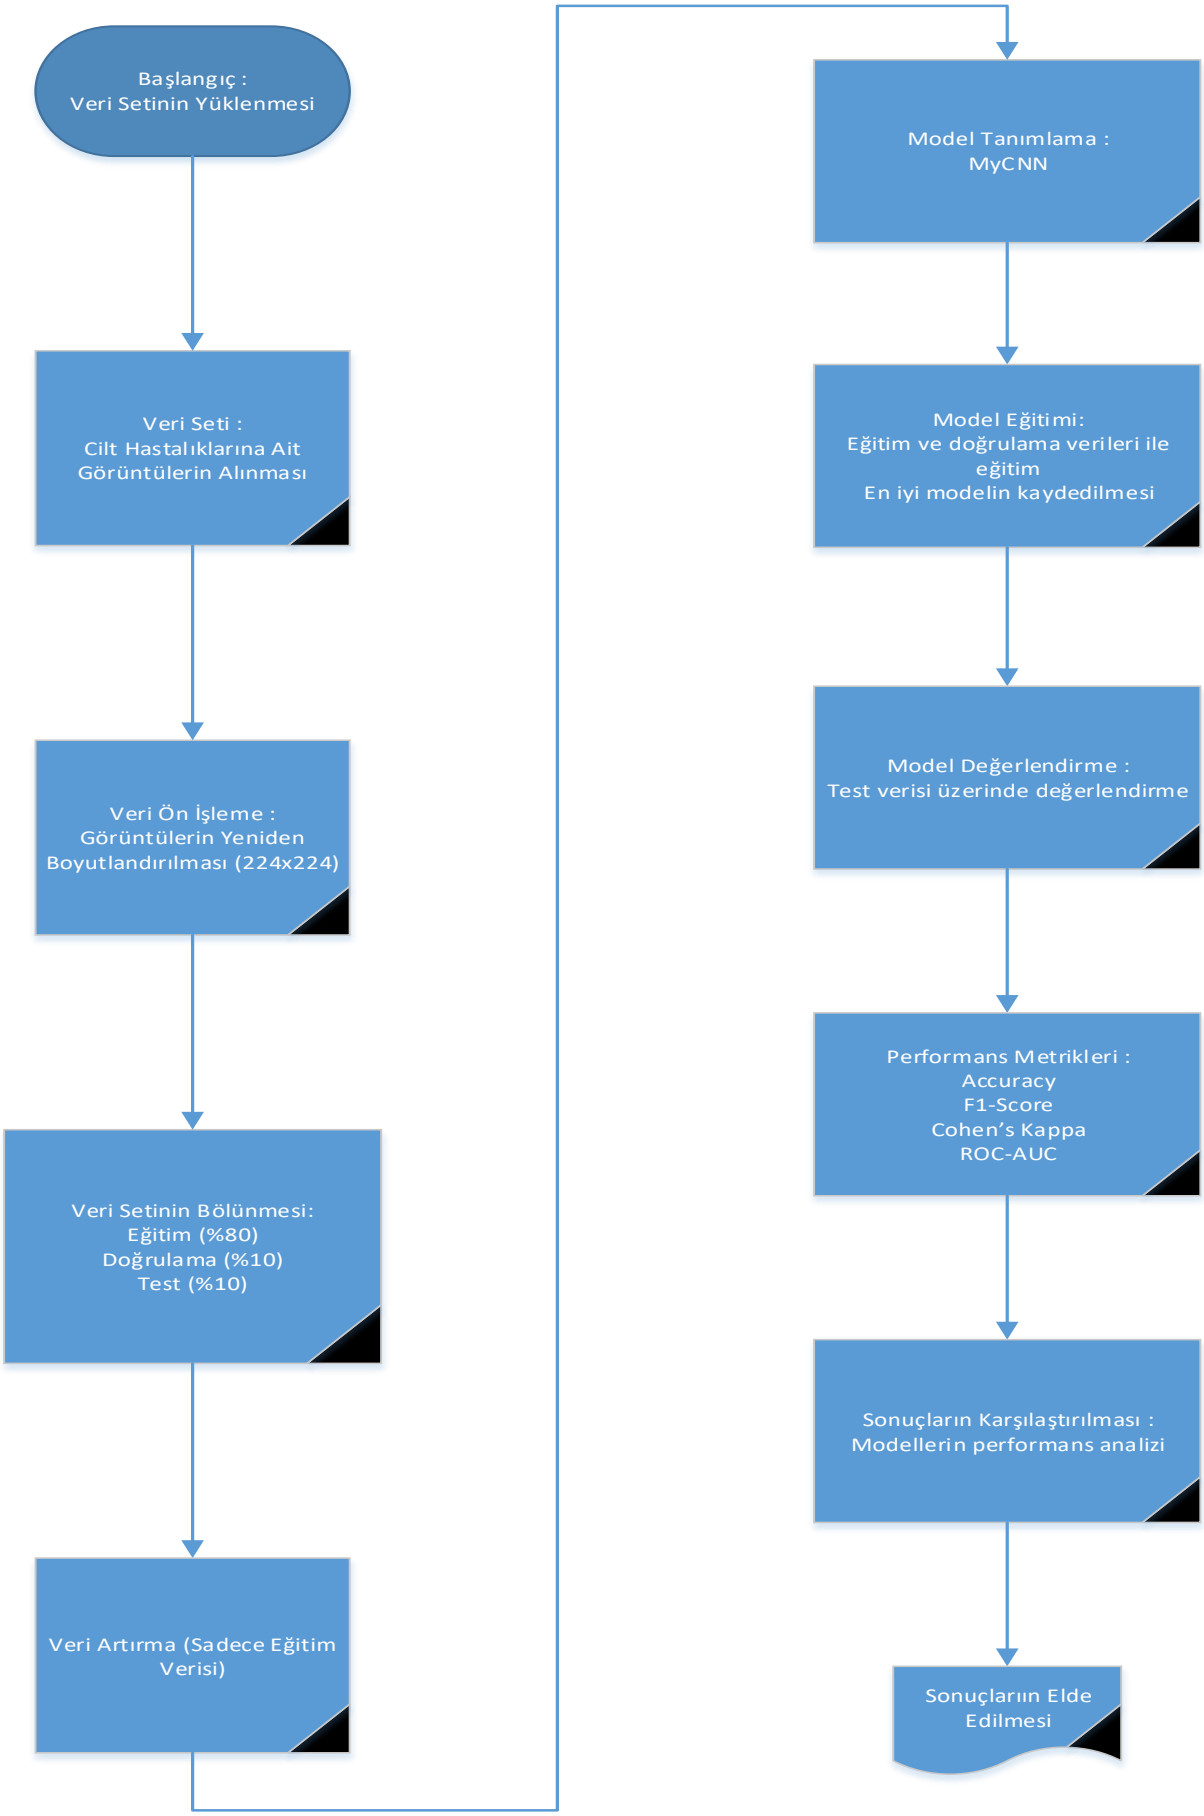
Başlangıç :
Veri Setinin Yüklenmesi
Veri Seti :
Cilt Hastalıklarına Ait
Görüntülerin Alınması
Veri Ön İşleme :
Görüntülerin Yeniden
Boyutlandırılması (224x224)
Veri Setinin Bölünmesi:
Eğitim (%80)
Doğrulama (%10)
Test (%10)
Veri Artırma (Sadece Eğitim
Verisi)
Model Tanımlama :
MyCNN
Model Eğitimi:
Eğitim ve doğrulama verileri ile
eğitim
En iyi modelin kaydedilmesi
Model Değerlendirme :
Test verisi üzerinde değerlendirme
Performans Metrikleri :
Accuracy
F1-Score
Cohen's Kappa
ROC-AUC
Sonuçların Karşılaştırılması :
Modellerin performans analizi
Sonuçlarıın Elde
Edilmesi

3.2. Veri Ön İşleme ve Hazırlık

Veri setinde yer alan görüntüler, derin öğrenme modellerinin giriş gereksinimlerine uygun hale getirilmek amacıyla çeşitli ön işleme adımlarından geçirilmiştir. İlk olarak, tüm görüntüler sabit bir giriş boyutuna dönüştürülmüş ve 224×224 piksel çözünürlüğe yeniden ölçeklendirilmiştir. Bu boyut, çalışmada kullanılan tüm modeller için ortak olarak belirlenmiştir.

Görüntülerin piksel değerleri normalize edilerek öğrenme sürecinin daha kararlı ve hızlı ilerlemesi sağlanmıştır. Ayrıca, yalnızca eğitim verileri üzerinde uygulanmak üzere veri artırma (data augmentation) tekniklerinden yararlanılmıştır. Bu teknikler, modelin farklı varyasyonlara karşı daha dayanıklı hale gelmesini ve aşırı öğrenmenin (overfitting) azaltılmasını amaçlamaktadır. Doğrulama ve test verileri ise gerçek dağılımı korumak adına veri artırma işlemlerinin dışında tutulmuştur.

Tablo 3.1. Veri setindeki sınıflara ait görüntü sayıları

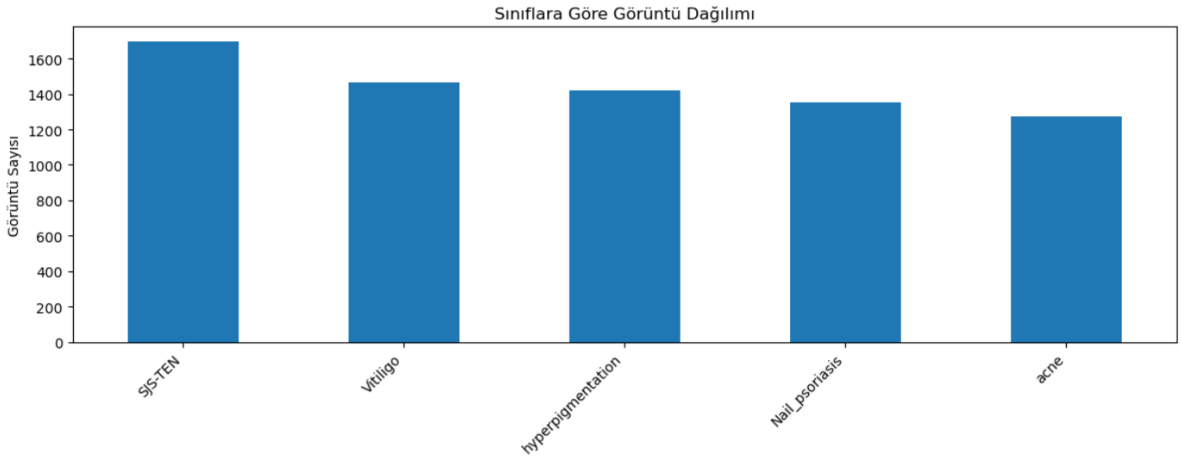

Şekil 3.2.Veri setinde yer alan her sınıfa ait örnek görüntüler

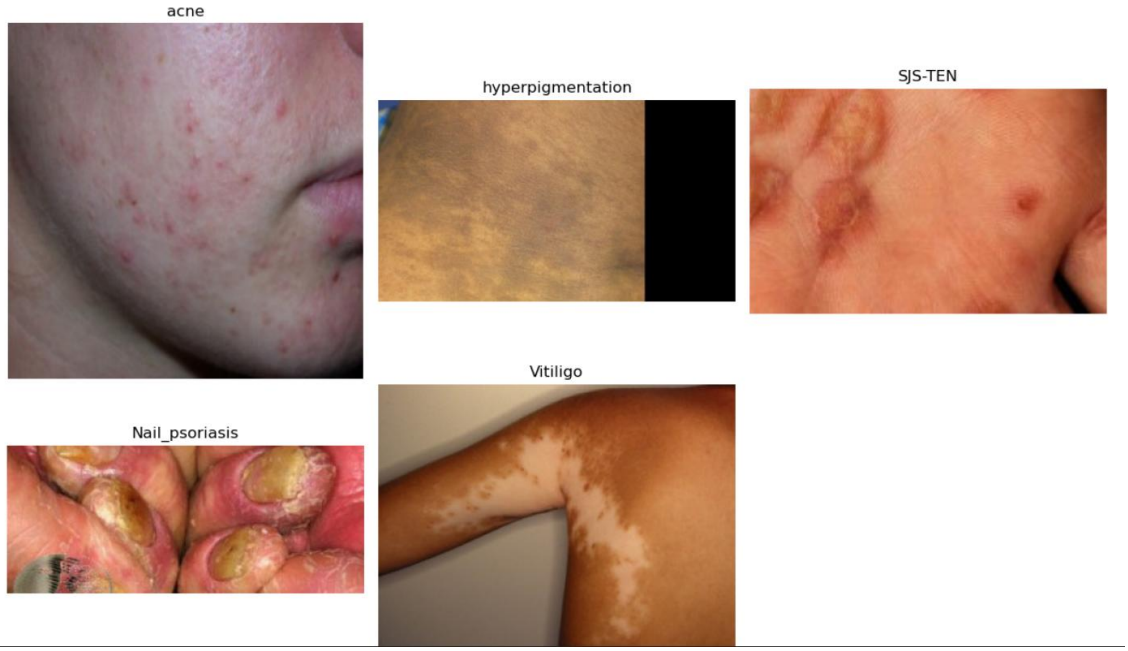

3.3. Kullanılan Derin Öğrenme Modelleri

Bu çalışmada toplam **11 farklı derin öğrenme modeli** kullanılmıştır. Modellerden biri sıfırdan tasarlanmış bir evrişimli sinir ağı (MyCNN) olup, diğerleri transfer öğrenme yaklaşımı ile önceden eğitilmiş modellerden oluşmaktadır.

Kullanılan modeller aşağıda listelenmiştir:

- MyCNN
- VGG16
- VGG19
- ResNet50
- ResNet101V2
- InceptionV3
- Xception
- DenseNet121
- MobileNetV2
- EfficientNetB0
- EfficientNetB3

Transfer öğrenme kullanılan modellerde, ImageNet veri seti üzerinde önceden eğitilmiş ağlar temel alınmış ve bu ağların son katmanları problem özelinde yeniden düzenlenmiştir. İlk aşamada, temel ağların ağırlıkları sabit tutulmuş ve yalnızca eklenen sınıflandırma katmanları eğitilmiştir.

3.4. Model Eğitimi

Tüm modeller, aynı eğitim ve doğrulama veri kümeleri kullanılarak eğitilmiştir. Eğitim sürecinde modellerin performansı doğrulama verisi üzerinde izlenmiş ve doğrulama kaybına göre en iyi model ağırlıkları kaydedilmiştir. Bu yaklaşım, modellerin aşırı öğrenmesini önlemeyi ve en iyi genelleme performansına sahip ağırlıkların seçilmesini amaçlamaktadır.

Eğitim sırasında erken durdurma ve öğrenme oranı azaltma gibi yöntemler kullanılarak eğitim süreci optimize edilmiştir. Böylece, gereksiz epoch'ların önüne geçilmiş ve eğitim süresi daha verimli hale getirilmiştir.

3.5. Performans Değerlendirme

Eğitim süreci tamamlandıktan sonra her bir model, daha önce hiç görülmemiş test verisi üzerinde değerlendirilmiştir. Performans değerlendirmesinde aşağıdaki metrikler kullanılmıştır:

- Doğruluk (Accuracy)
- Makro ortalamalı F1 skoru
- Cohen's Kappa katsayısı
- ROC–AUC (makro ortalama)
- Karışıklık matrisi (Confusion Matrix)

Bu metrikler sayesinde modellerin yalnızca genel doğrulukları değil, sınıflar arasındaki performans dengeleri de ayrıntılı olarak analiz edilmiştir.

4. DENEYSEL SONUÇLAR VE MODEL KARŞILAŞTIRMASI

Bu bölümde, çalışmada kullanılan derin öğrenme modellerinin test veri kümesi üzerindeki performansları sunulmakta ve elde edilen sonuçlar karşılaştırmalı olarak değerlendirilmektedir. Tüm modeller aynı eğitim, doğrulama ve test veri kümeleri kullanılarak eğitilmiş ve değerlendirilmiştir. Böylece elde edilen sonuçların adil ve karşılaştırılabilir olması sağlanmıştır.

4.1. Performans Değerlendirme Metrikleri

Modellerin performanslarını değerlendirmek amacıyla birden fazla metrik kullanılmıştır. Bu metrikler, yalnızca genel doğruluk oranını değil, sınıflar arasındaki başarı dengesini de dikkate alacak şekilde seçilmiştir. Çalışmada kullanılan değerlendirme metrikleri aşağıda listelenmiştir:

- **Doğruluk (Accuracy):** Modelin doğru sınıflandırdığı örneklerin toplam örnek sayısına oranını ifade etmektedir.
- **Makro Ortalamalı F1 Skoru:** Tüm sınıflar için hesaplanan F1 skorlarının ortalamasıdır ve sınıf dengesizliğine karşı daha duyarlı bir ölçüm sunmaktadır.
- **Cohen's Kappa Katsayısı:** Modelin rastgele tahminlere göre ne ölçüde daha iyi performans gösterdiğini ifade etmektedir.
- **ROC–AUC (Makro Ortalama):** Modellerin sınıfları ayırt etme yeteneğini ölçmek amacıyla kullanılmıştır.

Bu metrikler sayesinde modellerin performansları farklı açılardan değerlendirilmiş ve daha kapsamlı bir karşılaştırma yapılmıştır.

4.2. Model Karşılaştırma Sonuçları

Çalışmada kullanılan 11 farklı derin öğrenme modelinin test veri kümesi üzerinde elde ettiği sonuçlar karşılaştırmalı olarak incelenmiştir. Modellerin doğruluk, makro F1 skoru ve Cohen's Kappa değerleri Tablo 4.1'de sunulmaktadır.

Tablo 4.1. Modellerin test veri kümesi üzerindeki performansları

model	best_epoch	best_val_loss	best_val_accuracy	test_accuracy	test_f1_macro	test_kappa	roc_auc_macro
ResNet101V2	29	0.2222	0.9194	0.914	0.9149	0.8922	0.9911
InceptionV3	30	0.35	0.8708	0.8849	0.8873	0.8557	0.9801
DenseNet121	30	0.3488	0.8903	0.8724	0.872	0.84	0.9786
MobileNetV2	29	0.3171	0.8875	0.8655	0.8658	0.8316	0.9846
Xception	30	0.3688	0.8792	0.8627	0.8643	0.8281	
MyCNN	10	0.7776	0.7139	0.6935	0.6916	0.6193	
VGG16	30	10.213	0.6153	0.6491	0.6437	0.5613	
VGG19	30	11.141	0.5778	0.5839	0.5882	0.481	
ResNet50	30	15.055	0.3597	0.3759	0.3276	0.2161	
EfficientNetB0	30	16.045	0.2347	0.2358	0.0763	0.0	
EfficientNetB3	28	16.011	0.2347	0.2358	0.0763	0.0	

Elde edilen sonuçlar incelendiğinde, transfer öğrenme tabanlı modellerin genel olarak sıfırdan eğitilen MyCNN modeline kıyasla daha yüksek performans sergilediği görülmektedir. Özellikle **ResNet101V2** modeli, test veri kümesi üzerinde en yüksek doğruluk ve F1 skorunu elde ederek öne çıkmıştır. Bu durum, derin ve artık bağlantılara sahip mimarilerin karmaşık görsel örüntüleri daha etkili bir şekilde öğrenebildiğini göstermektedir.

MyCNN modeli ise, daha sınırlı parametre sayısına sahip olmasına rağmen kabul edilebilir bir performans sergilemiştir. Bu sonuç, özel olarak tasarlanan mimarinin temel sınıf ayrımlarını öğrenebildiğini ve kaynak kısıtlı ortamlarda alternatif bir çözüm sunabileceğini göstermektedir.

4.3. ROC–AUC Analizi

Modellerin sınıflar arası ayırt edicilik yeteneklerini değerlendirmek amacıyla seçilen bazı modeller için ROC–AUC analizi gerçekleştirilmiştir. Çok sınıflı sınıflandırma problemi için ROC eğrileri, makro ortalama yaklaşımı kullanılarak hesaplanmıştır.

Şekil 4.1. ResNet101V2 modeli için ROC eğrisi

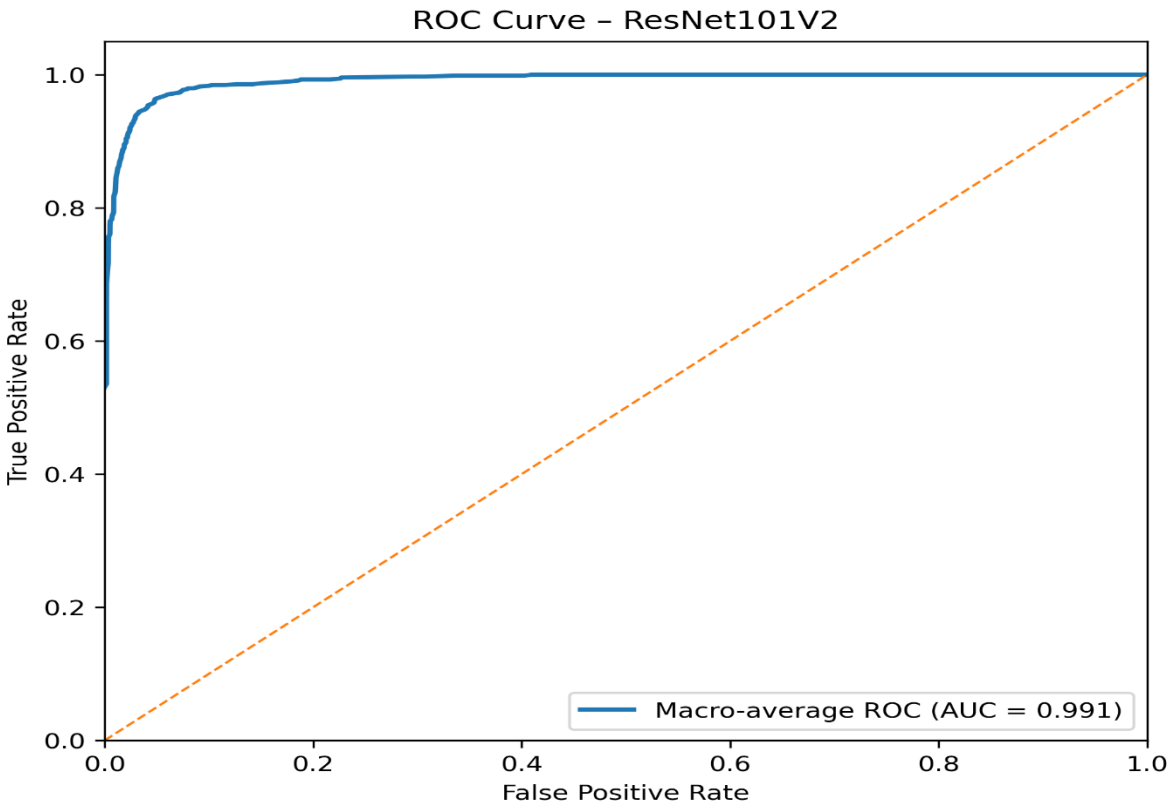

Şekil 4.2. MobileNetV2 modeli için ROC eğrisi

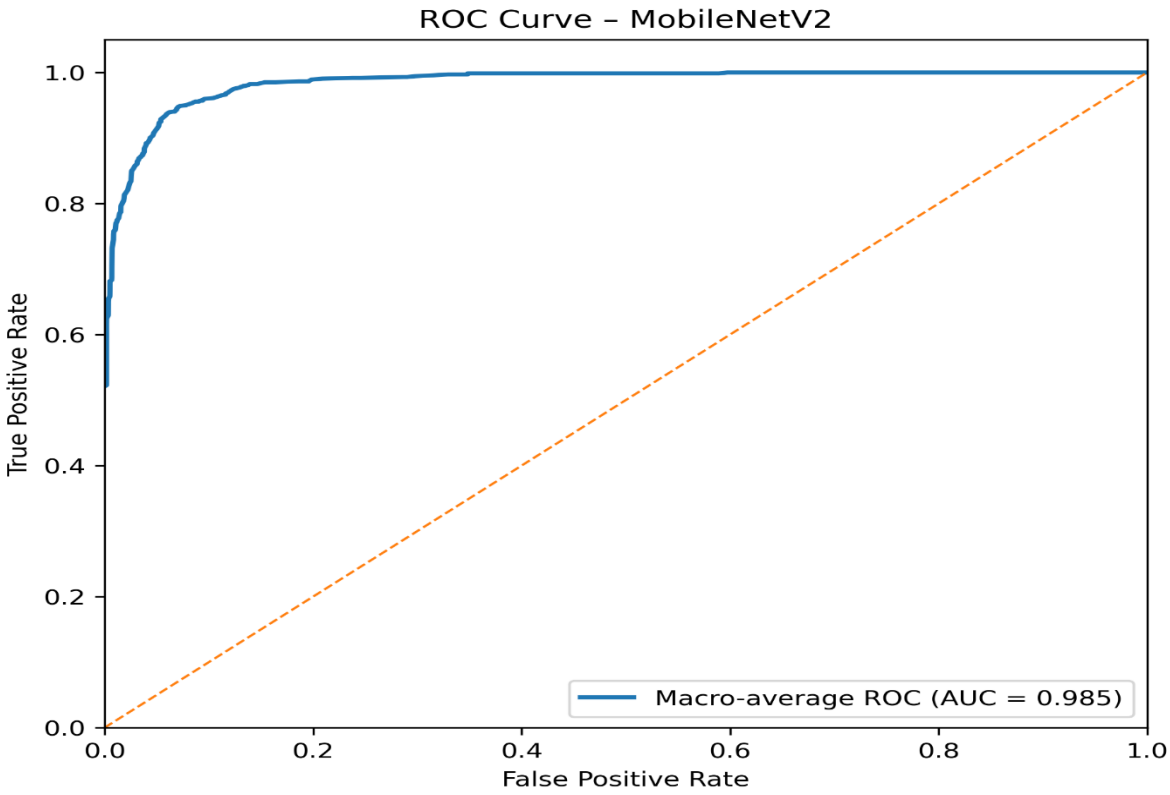

Şekil 4.3. InceptionV3 modeli için ROC eğrisi

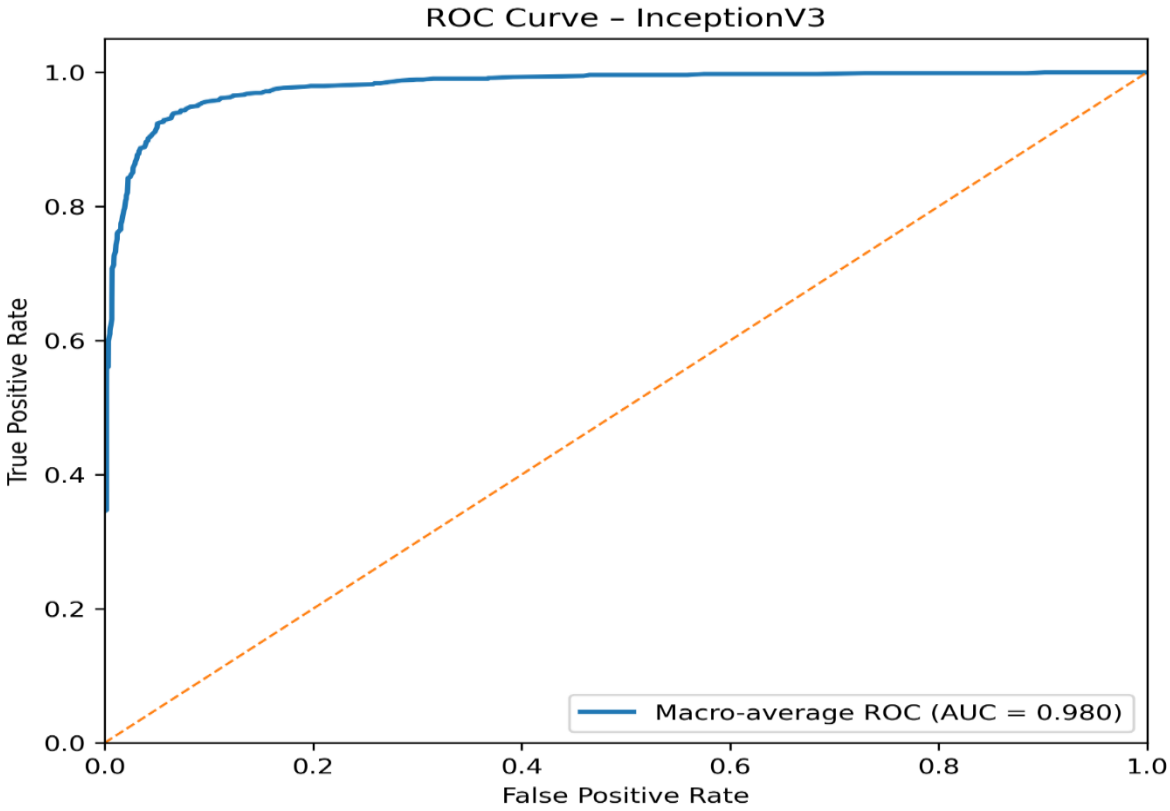

Şekil 4.4. DenseNet121 modeli için ROC eğrisi

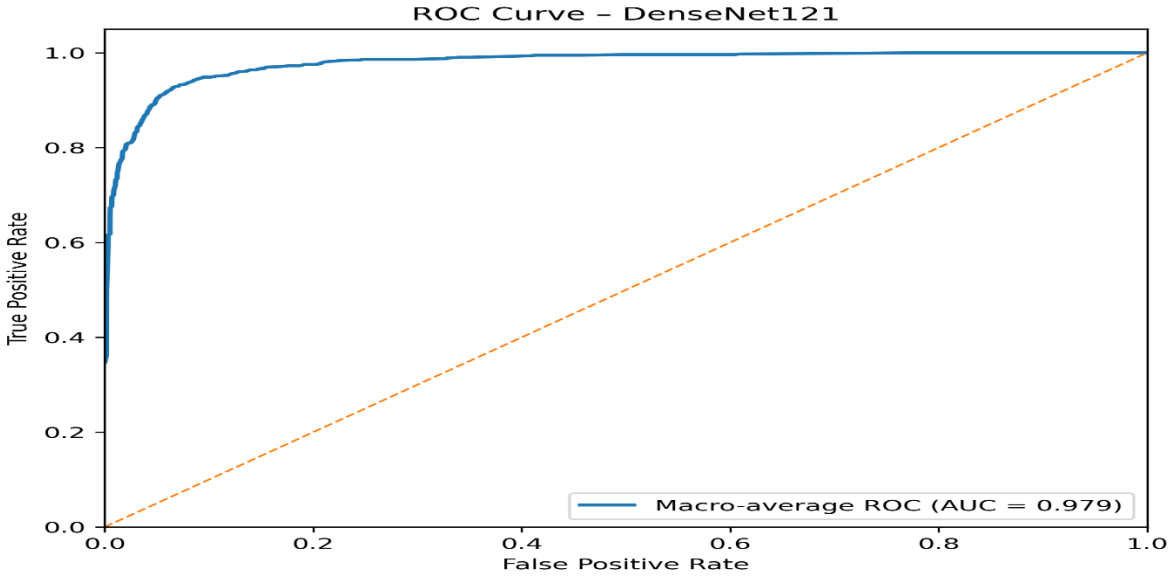

Elde edilen ROC–AUC sonuçları, özellikle ResNet101V2 modelinin yüksek ayırt edicilik yeteneğine sahip olduğunu göstermektedir. Diğer modeller de yüksek AUC değerleri elde etmiş ve sınıflar arasında başarılı bir ayrım gerçekleştirmiştir. Bu sonuçlar, doğruluk ve F1 skorları ile tutarlı bir performans sergilendiğini ortaya koymaktadır. Bu durum, modellerin yalnızca doğru sınıflandırma oranlarının değil, aynı zamanda sınıflar arasındaki ayırt edicilik yeteneklerinin de yüksek olduğunu göstermektedir.

4.4. Confusion Matrix Analizi

Model performanslarının daha ayrıntılı bir şekilde incelenebilmesi amacıyla her model için karışıklık matrisleri oluşturulmuştur. Confusion matrix'ler, modellerin hangi sınıflarda daha başarılı olduğunu ve hangi sınıflar arasında karışmalar yaşandığını görsel olarak ortaya koymaktadır.

Şekil 4.5. ResNet101V2 modeline ait karmaşıklık matrisi

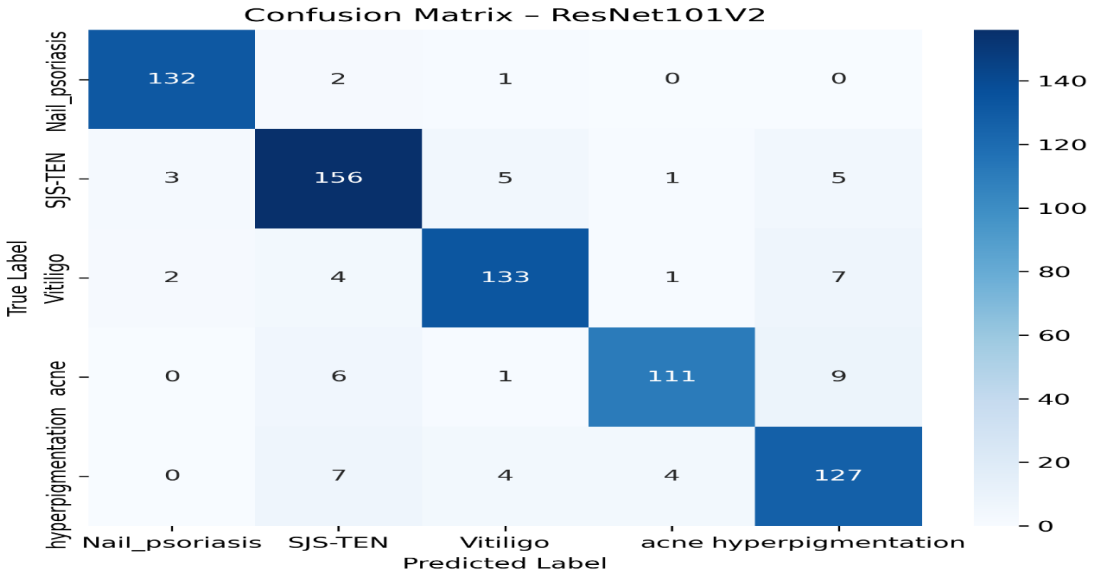

Şekil 4.6. MyCNN modeline ait karmaşıklık matrisi

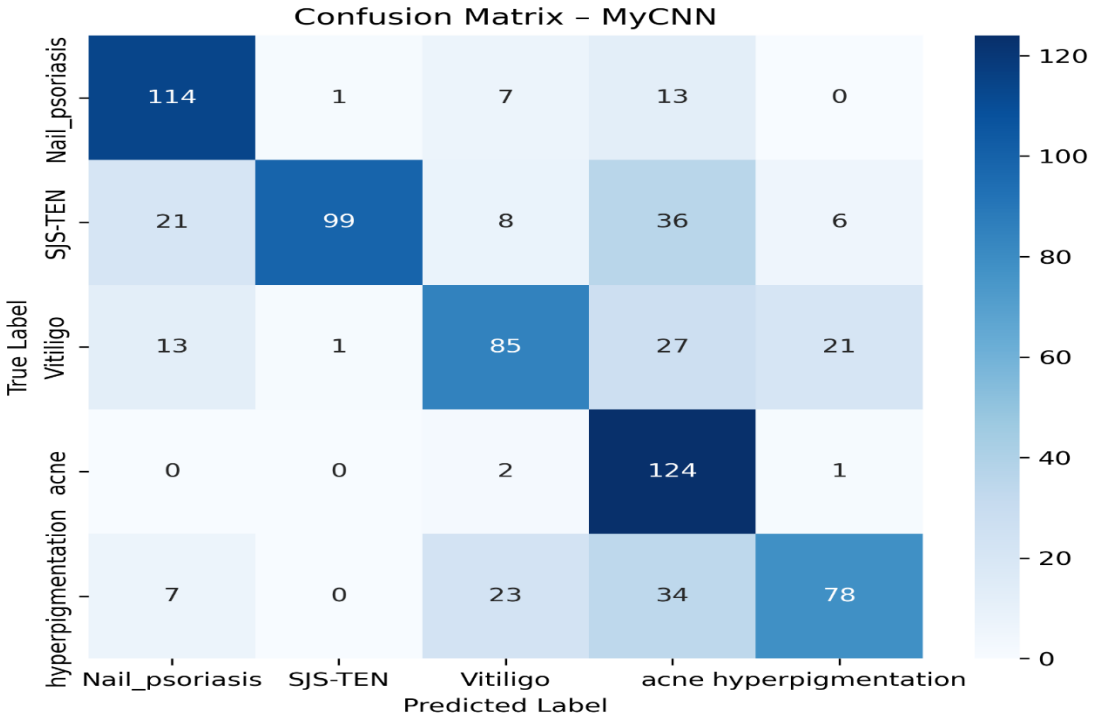

Şekil 4.7. MobileNetV2 modeline ait karmaşıklık matrisi

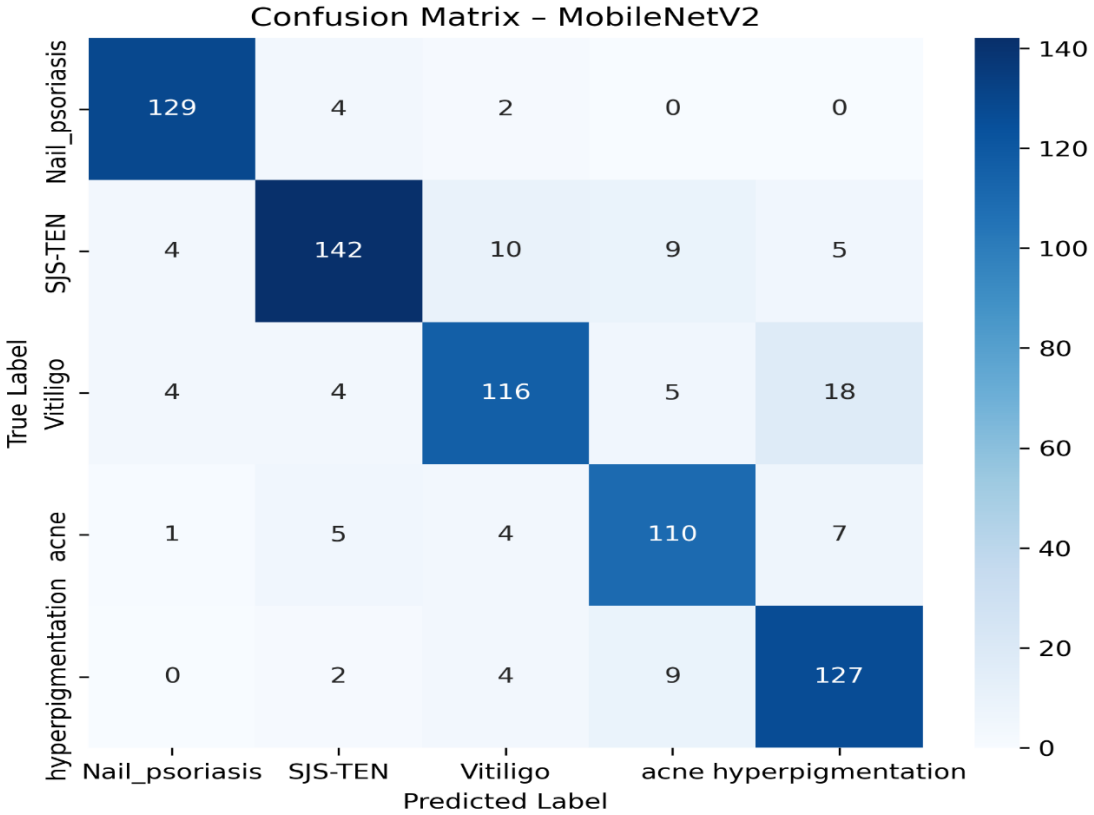

Şekil 4.8. InceptionV3 modeline ait karmaşıklık matrisi

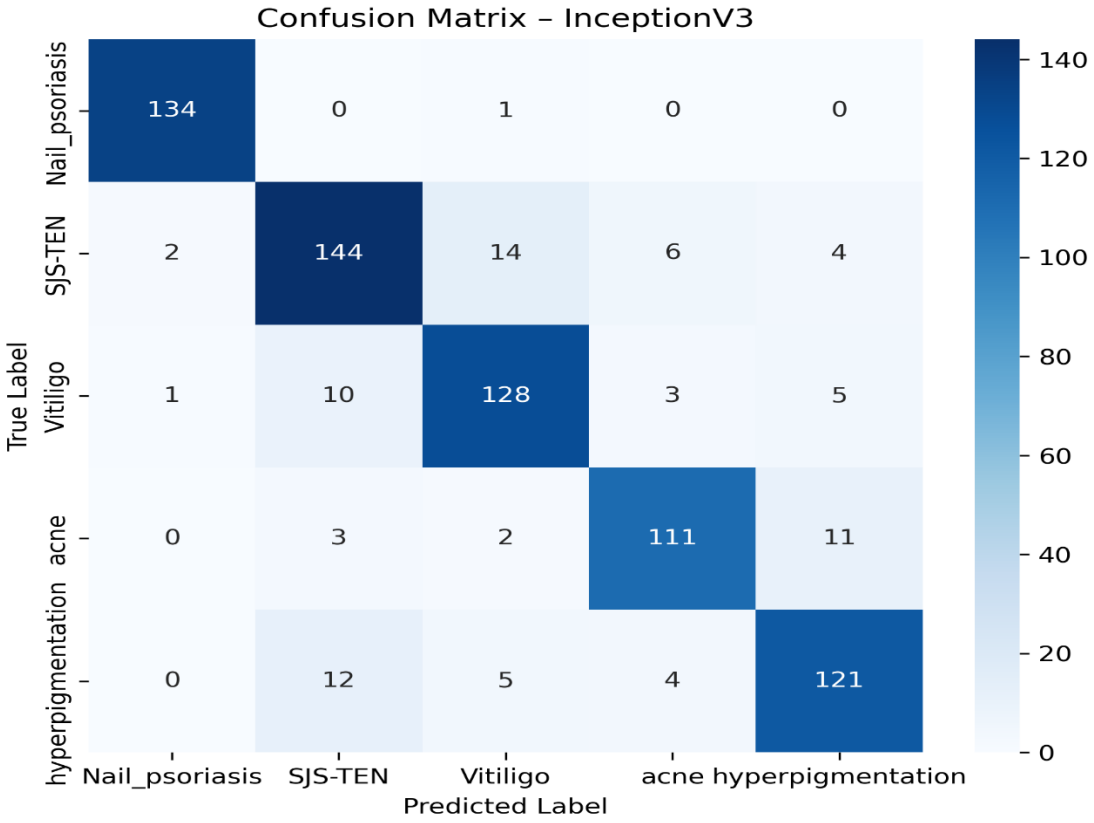

Şekil 4.9. DenseNet121 modeline ait karmaşıklık matrisi

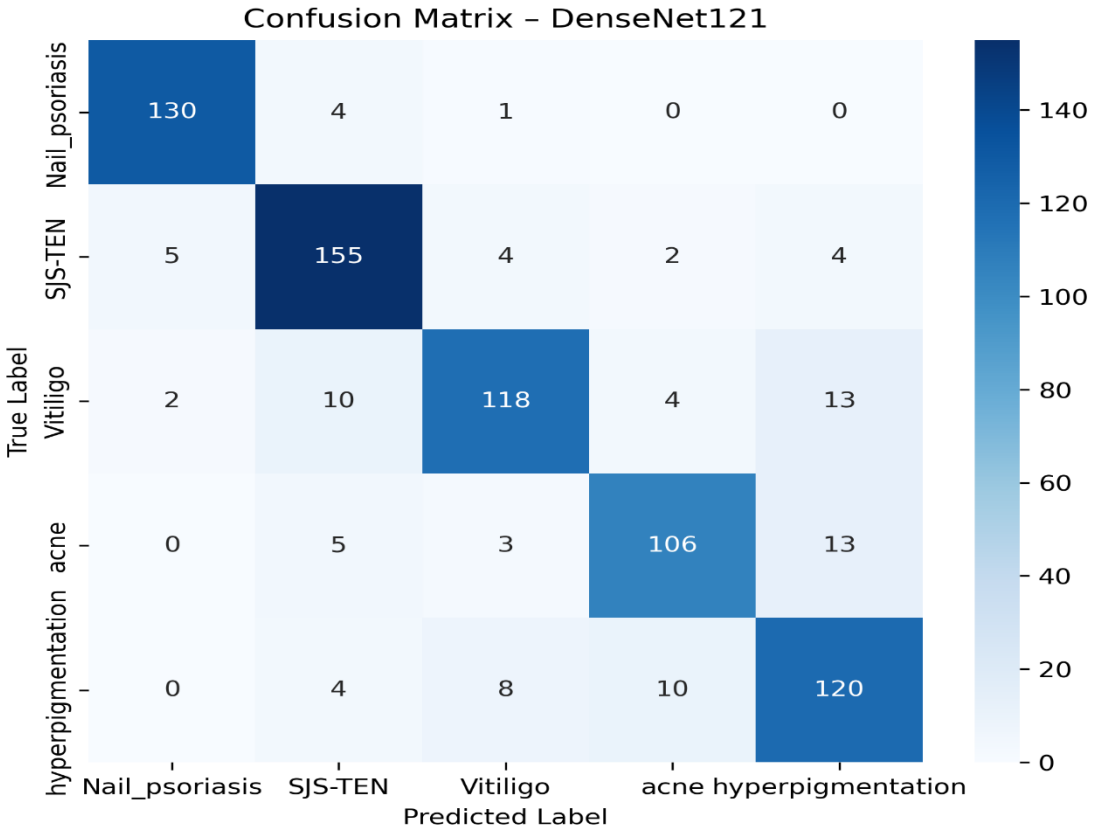

Karışıklık matrisleri incelendiğinde, yüksek performans sergileyen modellerin çoğu sınıfı doğru bir şekilde sınıflandırdığı görülmektedir. Yanlış sınıflandırmaların ise genellikle görsel olarak benzer özellikler taşıyan sınıflar arasında gerçekleştiği gözlemlenmiştir. Bu analizler, modellerin genel performans değerlendirmesinin daha güvenilir bir şekilde yapılmasına katkı sağlamıştır.

5. GENEL DEĞERLENDİRME VE SONUÇ

Bu raporda, cilt hastalıklarının görüntüler üzerinden sınıflandırılması problemi ele alınmış ve derin öğrenme tabanlı farklı modellerin performansları karşılaştırmalı olarak incelenmiştir. Çalışma kapsamında bir adet özel olarak tasarlanmış evrişimli sinir ağı modeli (MyCNN) ile birlikte transfer öğrenme yaklaşımı kullanan çeşitli derin öğrenme modelleri değerlendirilmiştir.

Elde edilen deneysel sonuçlar, transfer öğrenme tabanlı modellerin genel olarak sıfırdan eğitilen MyCNN modeline kıyasla daha yüksek performans sergilediğini göstermiştir. Özellikle ResNet101V2 modeli, test veri kümesi üzerinde en yüksek doğruluk ve F1 skorunu elde ederek öne çıkmıştır. Bu durum, derin ve artık bağlantılara sahip mimarilerin karmaşık görsel örüntüleri daha etkili bir şekilde öğrenebildiğini ortaya koymaktadır.

MyCNN modeli ise daha sınırlı bir mimariye sahip olmasına rağmen kabul edilebilir bir performans sunmuştur. Bu sonuç, özel olarak tasarlanan daha hafif modellerin, özellikle hesaplama kaynaklarının kısıtlı olduğu ortamlarda alternatif bir çözüm olarak değerlendirilebileceğini göstermektedir.

Çalışmada kullanılan değerlendirme metrikleri (doğruluk, makro F1 skoru, Cohen’s Kappa ve ROC–AUC) sayesinde modellerin performansları farklı açılardan analiz edilmiş ve sonuçların tutarlılığı ortaya konmuştur. Ayrıca, karışıklık matrisleri yardımıyla sınıf bazlı başarılar detaylı olarak incelenmiştir.

Sonuç olarak, bu çalışma derin öğrenme yöntemlerinin cilt hastalıklarının otomatik sınıflandırılmasında etkili bir şekilde kullanılabileceğini göstermektedir. Elde edilen bulgular, ders kapsamında gerçekleştirilen bu uygulama çalışmasının amacına ulaştığını ve farklı model yaklaşımlarının karşılaştırılmasına olanak sağladığını ortaya koymaktadır.